UNIVERSITÀ DI PISA

Decision Support Systems Project

Large Analysis of a Music Streaming Service

Authors:
Fabrizio Furnari (694419)
Giulia Mela (618133)
Ilenia Fortuna (618158)

Course:
Decision Support Systems
MSc in Data Science and Business Informatics

Indice

1 Introduzione **4**

2 Data Understanding & Preparation **5**

2.1 Data Understanding (Assignment 1) 5

2.1.1 Analisi del Dataset Tracce (tracks.json) 5

2.1.2 Analisi del Dataset Artisti (artists.xml) 6

2.1.3 Verifica Chiavi Primarie: Il problema delle "Collisioni Semantiche" 7

2.2 Data Cleaning Strategy (Assignment 2) 7

2.2.1 Rigenerazione degli Identificativi 7

2.2.2 Normalizzazione dei Formati e Standardizzazione 7

2.2.3 Coerenza Semantica (Majority Vote) 8

2.3 Data Enrichment (Assignment 2b) 8

2.4 Song Profiling (Assignment 3) 9

3 Data Warehouse Architecture **10**

3.1 Strategia di Modellazione Dimensionale (Assignment 4) 10

3.1.1 Gestione delle Relazioni N:M (Analisi Comparativa) 11

3.1.2 Fact Table: FactSongStreams 12

3.2 Data Splitting (Assignment 5) 12

3.2.1 Gestione dei file e struttura del codice 12

3.2.2 Logica generale di splitting 13

3.3 Data uploading with Python (Assignment 6) 15

4 ETL Implementation with SSIS **15**

4.1 Data Warehouse Population Using SSIS (Assignment 7) 15

4.1.1 Control Flow 16

4.1.2 Sampling Strategy per l'Ottimizzazione del Testing 16

4.2 Artist Production (Assignment 8) 17

4.3 Seasonality Score (Assignment 9) 18
4.4 Analisi delle metriche regionali e per categoria musicale (Assignment 10) 18
4.5 Advanced Artist Statistics (Assignment 11) 20
4.6 Business Insight: analisi dell'impatto stagionale (Assignment 12) 22
4.7 Valutazione degli Artisti e Strategie di Portafoglio (Assignment 13) 24

5 OLAP Cube Design **26**
5.1 Cube Structure (Assignment 14) 26
5.1.1 Dimensions and Hierarchies 27
5.1.2 Measures 28
5.2 Advanced Modeling: PseudoFact e Weighted Analysis 28

6 MDX Analysis **29**
6.1 Stream mensili per regione (Assignment 15) 29
6.2 Stream ponderati degli artisti (Assignment 16) 30
6.3 Trend annuali delle categorie musicali (Assignment 17) 31
6.4 Categorie con performance stagionali superiori alla media (Assignment18) 33
6.5 Analisi avanzata di business (Assignment 19) 34

7 Dashboards & Visual Analytics **35**
7.1 Analisi geografica per categoria (Assignment 20) 35
7.2 Analisi dei testi delle canzoni (Assignment 21) 36
7.3 Trend temporali delle categorie musicali (Assignment 22) 37

8 Conclusion **38**

Elenco delle figure

1 Snowflake Schema 10
2 Relazione Many-to-Many tramite Bridge Table 11
3 SSIS Control Flow 16
4 Data Source View 27
5 Dimension Usage 28
6 Plot per l'Assignment 20 36
7 Primo plot per l'Assignment 21 37
8 Secondo plot per l'Assignment 21 37
9 Plot per l'Assignment 22 38

Elenco delle tabelle

1 Esempio di output della query MDX: stream mensili per regione e totale nazionale 30
2 Esempio di output della query MDX: indicatore AvgYearlyArtistStreams per anno . 31
3 Esempio di output della query MDX: variazione percentuale degli stream per categoria rispetto all'anno precedente 32
4 Esempio di output della query MDX: categorie con stream superiori alla media stagionale dell'anno precedente 34
5 Esempio di output (Assignment 19): top casi con aumento positivo della quota rispetto all'anno precedente. 35

Indice delle Query

1 Monthly Streams By Region 29
2 Weighted Artist Streams 31
3 Yearly Category Trends 32
4 Seasonal Over-Performers 33
5 Advanced MDX Insight: Top Growing Categories 34

1. Introduzione

Il progetto verte sulla progettazione e implementazione di un sistema di Business Intelligence per una casa discografica, finalizzato all'elaborazione di dataset eterogenei per derivare insight strategici nel mercato dello streaming digitale. L'analisi si fonda su due sorgenti dati complementari.

Il primo dataset è costituito da una collezione semi-strutturata (in formato JSON) che fornisce metadati dettagliati sulle tracce musicali. Ogni record contiene ricche informazioni descrittive, spaziando dalle metriche identificative alle caratteristiche audio tecniche, fino agli indicatori di performance come il numero di stream al primo mese e i punteggi di popolarità. Questo dataset offre un'istantanea completa delle performance del catalogo, permettendo un ampio spettro di analisi sulle preferenze degli ascoltatori e sulle caratteristiche dei brani.

Il secondo dataset segue una struttura gerarchica (in formato XML) e si concentra sull'anagrafica degli artisti. Esso cattura attributi demografici e geografici, incluse date di nascita, dettagli sulla provenienza e periodi di attività. Sebbene essenziale per la profilazione, questa sorgente ha richiesto una significativa integrazione e arricchimento per essere allineata ai dati transazionali delle tracce.

Per gestire la complessità di questi input non strutturati, il progetto adotta un approccio architetturale a più livelli (*Multi-Layer Architecture*). Il flusso di lavoro spazia dalla preparazione del dato grezzo alla costruzione di un Data Warehouse strutturato, culminando nell'analisi multidimensionale. Tale struttura è progettata per trasformare osservazioni isolate in un sistema di supporto decisionale coeso, essenziale per valutare i rischi di investimento, identificare i trend stagionali e ottimizzare la strategia di portafoglio della label.

Data Preparation (Python) Si è partiti da un'analisi preliminare dei dati sorgente, che ha evidenziato subito diverse criticità in termini di qualità e consistenza. Per questo motivo, la prima fase è stata svolta in Python: questo ha permesso di "sanificare" i dati, gestire i valori nulli e arricchire il dataset con informazioni esterne (come i generi musicali o i dati anagrafici mancanti) in modo flessibile, prima di vincolarli in uno schema rigido.

Data Warehousing (SQL Server) Successivamente, si è passati alla progettazione del Data Warehouse. In questa fase, la decisione fondamentale è stata quella di abbandonare la logica transazionale per adottare uno schema a stella (*Star Schema*), scelta necessaria per favorire le performance di lettura e facilitare le future query analitiche.

ETL (SSIS) Per popolare questo schema, non si è proceduto manualmente ma tramite implementazione dei flussi ETL automatizzati (*SQL Server Integration Services*). Questo ha garantito non solo il caricamento efficiente dei dati, ma anche la possibilità di inserire logiche di trasformazione complesse e calcoli intermedi (come i punteggi di stagionalità) direttamente nel flusso di alimentazione.

Multidimensional Analysis (SSAS) Infine, per colmare il divario tra il database tecnico e l'utente finale, è stato sviluppato un cubo OLAP con *Analysis Services*. Questo strato semantico è stato cruciale per pre-calcolare le aggregazioni e definire le gerarchie, permettendo così allo strumento di visualizzazione finale, **Power BI**, di interrogare il sistema in modo reattivo e dinamico, senza dover elaborare milioni di righe in tempo reale.

In sintesi, il progetto dimostra come l'integrazione ragionata di questi strumenti permetta di trasformare dati eterogenei e disordinati in un modello decisionale affidabile, capace di guidare anche un utente meno esperto nella gestione del proprio portafoglio artisti.

2. Data Understanding & Preparation

Il presente capitolo illustra il processo di analisi esplorativa e pre-elaborazione dei dati, svolto integralmente in ambiente Python. Prima di procedere alla modellazione architetturale del Data Warehouse, si è ritenuto fondamentale eseguire una validazione approfondita dei dataset sorgente ("Raw Data"), al fine di valutarne non solo la correttezza sintattica, ma soprattutto la coerenza semantica e informativa. Questa indagine preliminare non si è limitata alla verifica tecnica dei formati, ma ha avuto l'obiettivo di valutare la qualità intrinseca delle informazioni a disposizione. Prima di poter definire qualsiasi struttura o gerarchia, era infatti fondamentale accertare la consistenza dei dati anagrafici, la validità delle informazioni temporali e l'effettiva disponibilità degli attributi necessari alle analisi richieste. Senza questo passaggio di validazione semantica, sarebbe stato impossibile definire strategie di pulizia efficaci e garantire una base informativa solida per le fasi successive del progetto. Il flusso di lavoro è stato strutturato in tre stadi logici sequenziali: Analisi (*Understanding*), Pulizia (*Cleaning*) e Arricchimento (*Enrichment*), ciascuno volto a risolvere specifiche criticità di qualità del dato emerse durante lo studio preliminare.

2.1. Data Understanding (Assignment 1)

La fase inaugurale del progetto ha avuto come obiettivo l'analisi strutturale e qualitativa dei due dataset forniti: `tracks.json` e `artists.xml`. Utilizzando script Python dedicati, non ci si è limitati a caricare i dati, ma ne a profilarne il contenuto per valutare la consistenza, la completezza e, soprattutto, l'affidabilità delle chiavi primarie, elemento critico per la futura costruzione del DW.

2.1.1 Analisi del Dataset Tracce (tracks.json)

Il dataset si compone di **11.166 brani musicali**. Dall'ispezione preliminare, il file risulta strutturalmente solido: ogni record possiede il 100% delle chiavi previste dallo schema JSON, coprendo

un ampio spettro informativo che spazia dai metadati anagrafici alle feature audio (come BPM e loudness) fino alle metriche testuali. Tuttavia, l'analisi dei valori nulli (*Missing Values*) ha fatto emergere due scenari distinti che richiederanno strategie diverse in fase di pulizia:

- **Mancanze Fisiologiche:** Il campo `featured_artists` è vuoto nel 68.5% dei casi. Questo dato non rappresenta un errore di qualità, ma riflette semplicemente la natura del dominio musicale (non tutti i brani prevedono collaborazioni esterne).
- **Inconsistenza Gerarchica delle Date:** Abbiamo rilevato una progressiva perdita di dettaglio nelle informazioni temporali. Mentre l'anno (`year`) è quasi sempre presente (manca solo nel 4% dei casi), il mese e il giorno mancano rispettivamente nel 10.7% e 11.8% dei record, ciò significa che è spesso noto l'anno di uscita ma non la data precisa. Per ovviare a questo problema, si è deciso di costruire una logica di "fallback": laddove la data traccia è incompleta, verrà utilizzata la `album_release_date` (tasso di completezza del 99.3%) come riferimento affidabile per derivare le dimensioni temporali. Da questa informazione consolidata sarà poi possibile derivare la *Stagione* di uscita.

Fortunatamente, i campi chiave `title` e `primary_artist` sono presenti nel 100% dei record, garantendo la piena identificabilità semantica di ogni brano.

2.1.2 Analisi del Dataset Artisti (artists.xml)

Il file contiene le anagrafiche di **104 artisti**, organizzate in nodi XML. A differenza delle tracce, qui saltano all'occhio lacune critiche che, se ignorate, avrebbero reso impossibili le analisi geografiche richieste dal management. I dati sulla provenienza mancano per circa un terzo degli artisti:

- **Geografia:** Provincia, Regione e Nazione risultano assenti o nulle in una percentuale variabile tra il 32.7% e il 34.6%.
- **Dati Biografici:** Anche luogo e data di nascita mancano in circa il 30% dei casi.
- **Dati di Carriera:** Il campo `active_end` è vuoto per il 100% degli artisti (tutti risultano in attività), mentre `active_start` manca in oltre la metà dei casi (51.9%). Data la scarsa affidabilità per analisi storiche, **si è deciso di escludere entrambi gli attributi dal dataset finale**, eliminando il rumore informativo.

Conclusione: Il dataset artisti grezzo è insufficiente. È quindi indispensabile pianificare un processo di **Data Enrichment** (via Wikidata) per recuperare le informazioni mancanti e popolare correttamente le dimensioni geografiche.

2.1.3 Verifica Chiavi Primarie: Il problema delle "Collisioni Semantiche"

Il risultato più significativo di questa fase è emerso dal controllo di integrità sugli identificatori (`id`). Mentre il campo **ID** degli artisti ha superato il test di univocità e verrà mantenuto come riferimento valido, non si può dire lo stesso del campo **ID** delle tracce. Un primo controllo superficiale aveva evidenziato alcuni duplicati tecnici, ma un'analisi più approfondita ha rivelato una criticità strutturale ben più grave. Sono stati individuati numerosi casi in cui lo stesso identificativo numerico veniva utilizzato impropriamente per rappresentare coppie *(Titolo, Artista)* completamente diverse. Di fronte a questa evidenza, l'ID originale fornito nel JSON è stato giudicato inaffidabile come Chiave Primaria (PK). La strategia correttiva per la fase successiva (Assignment 2) sarà quindi radicale:

1. Ignorare l'ID sorgente per l'identificazione univoca.
2. Risolvere i duplicati basandosi sulla "firma" reale del brano (combinazione Titolo-Artista).
3. Generare ex-novo dei **UUID sintetici** per ogni traccia, garantendo così l'integrità referenziale assoluta all'interno del Data Warehouse.

2.2. Data Cleaning Strategy (Assignment 2)

Dopo aver identificato le criticità strutturali nella fase di analisi, si è passati all'implementazione della pipeline di pulizia. L'obiettivo primario non è stato applicare correzioni generiche, ma trasformare dati eterogenei in un formato rigoroso e compatibile con i vincoli del Data Warehouse.

2.2.1 Rigenerazione degli Identificativi

Il primo intervento ha riguardato la risoluzione delle collisioni sugli ID originali. Poiché i codici forniti nel JSON non garantivano l'univocità semantica, abbiamo adottato una strategia radicale: invece di tentare correzioni puntuali, abbiamo deduplicato i brani basandoci sulla combinazione *Titolo-Artista* e generato per ciascuno un nuovo identificativo univoco (**UUID**). L'ID originale è stato mantenuto esclusivamente come attributo di tracciabilità (*lineage*), garantendo così l'integrità referenziale del sistema.

2.2.2 Normalizzazione dei Formati e Standardizzazione

Il formato JSON di origine presentava una notevole flessibilità che mal si adattava alla rigidità di uno schema relazionale. È stato quindi necessario uniformare i tipi di dato e rimuovere le ridondanze:

Liste e Stringhe complesse

Molti attributi (es. *featured artists*, liste di parole) si presentavano come stringhe di testo mal formattate. È stata implementata una logica di parsing dedicata per interpretare queste strutture e convertirle in liste pulite, rimuovendo caratteri speciali e/o sconosciuti.

Valori Booleani

Campi come *explicit* presentavano valori misti ("true", "1", "yes"). Sono stati tutti convertiti in standard binario (0/1) per assicurare la compatibilità con il database.

Feature Pruning (Rimozione Tecnica)

Per ottimizzare il Data Warehouse, sono state rimosse le colonne transitorie o ridondanti. Le coordinate grezze (`latitude`, `longitude`) sono state scartate in quanto sostituite dalle gerarchie regionali, mentre attributi come `language` o `album_name` (già presenti nelle dimensioni o desumibili dal contesto) sono stati eliminati.

2.2.3 Coerenza Semantica (Majority Vote)

Un'attenzione particolare è stata dedicata alla pulizia dei nomi degli album, spesso presenti con lievi variazioni (es. "Album X" vs "Album X Deluxe") pur avendo lo stesso ID. Per evitare duplicazioni nel database, abbiamo applicato un algoritmo di *Majority Vote* (moda statistica): lo script identifica la variante del nome più frequente per ogni ID album e la impone uniformemente a tutte le tracce associate.

2.3. Data Enrichment (Assignment 2b)

Al termine della fase di pulizia, il dataset presentava ancora lacune significative nella dimensione geografica (circa il 30% di dati mancanti). Per colmare questo gap è stato adottato un approccio ibrido a due livelli: una risoluzione geometrica locale seguita da un'integrazione semantica remota.

1. Risoluzione Geometrica (Point-in-Polygon)

Prima di interrogare servizi esterni, il sistema tenta di inferire le informazioni amministrative (Regione, Nazione) sfruttando le coordinate geografiche (latitudine/longitudine) già presenti nel dataset originale. Utilizzando la libreria `Shapely`, viene applicato un algoritmo di *Point-in-Polygon*: ogni coordinata artista viene intersecata con i poligoni dei confini amministrativi ufficiali. Questo approccio garantisce l'assegnazione certa della regione di appartenenza, eliminando gli errori di digitazione nei nomi delle città.

2. Integrazione API Wikidata e Scoring

Per le entità non risolte geometricamente o prive di coordinate, il modulo interroga le API di **Wikidata**. La sfida tecnica principale è stata la gestione delle omonimie (es. distinguere l'artista "Alfa"

dalla lettera greca). Per garantire la qualità del dato, è stato implementato un algoritmo di **Scoring Semantico**:

- Il sistema analizza i metadati restituiti e assegna un punteggio positivo (+3) in presenza di keyword pertinenti al dominio musicale (es. *cantante, rapper, band*).
- Assegna penalità drastiche (-5) in presenza di termini fuori contesto (es. *politica, scienza, oggetti*).

Solo le entità che superano una soglia di confidenza vengono integrate. Inoltre, per rispettare le policy delle API pubbliche, è stato applicato un *Rate Limiting* adattivo, inserendo un ritardo intenzionale tra le richieste per evitare il blocco dell'IP. Il risultato finale è un dataset arricchito in cui, partendo da informazioni frammentarie, sono state ricostruite gerarchie geografiche complete.

2.4. Song Profiling (Assignment 3)

Per il profiling dei brani è stata realizzata una categorizzazione *data-driven* sfruttando le informazioni melodiche e testuali. Il processo è stato strutturato in tre fasi logiche: estrazione delle feature, esecuzione dell'algoritmo e interpretazione semantica.

Feature Engineering e Normalizzazione. Per ogni traccia è stato costruito un vettore di feature numeriche multidimensionale. Il set informativo combina metriche audio tecniche (BPM, loudness, flatness, flux, spectral complexity, pitch, RMS, rolloff) con metriche derivate dal Natural Language Processing (numero di token, frequenza di parole esplicite in italiano/inglese e flag *explicit*). Data l'eterogeneità delle unità di misura, è stato applicato un pre-processing essenziale: tutte le variabili sono state normalizzate tramite **Z-Score Normalization**. Questo passaggio ha reso confrontabili grandezze con ordini di grandezza differenti, garantendo che il calcolo della distanza euclidea non fosse dominato da variabili a scala maggiore (come il BPM) a discapito di quelle a scala ridotta (come la spectral complexity).

Algoritmo e Interpretazione dei Cluster. Il clustering è stato effettuato mediante un'implementazione manuale dell'algoritmo **K-Means**. Per garantire la riproducibilità scientifica dei risultati è stato fissato un seed randomico e il numero di cluster è stato impostato a $k = 6$. L'analisi a posteriori dei centroidi ha permesso di assegnare etichette interpretabili: `SOFT POP`, `MINIMAL`, `RAP` (valori massimi di token e parole esplicite), `POP`, `DANCE` (alta ritmica e BPM) e `URBAN`.

Raffinamento e Validazione. In fase di revisione, è stata analizzata la consistenza del cluster `URBAN`, risultato numericamente esiguo (68 brani). È stata valutata l'ipotesi di accorparlo ad altri gruppi per ridurre la frammentazione, ma l'analisi delle distanze ha portato a scartare questa opzione. Forzare l'unione avrebbe introdotto una distorsione geometrica, accorpando brani semanticamente distanti e aumentando la varianza interna (intra-cluster variance). Si è scelto dunque di mantenere la configurazione a 6 cluster per preservare la purezza dei centroidi.

3. Data Warehouse Architecture

Il presente capitolo illustra l'architettura logica e fisica del Data Warehouse implementato su Microsoft SQL Server. Il modello adottato è un *Snowflake Schema*, progettato per gestire relazioni complesse e dati eterogenei senza sacrificare l'integrità referenziale.

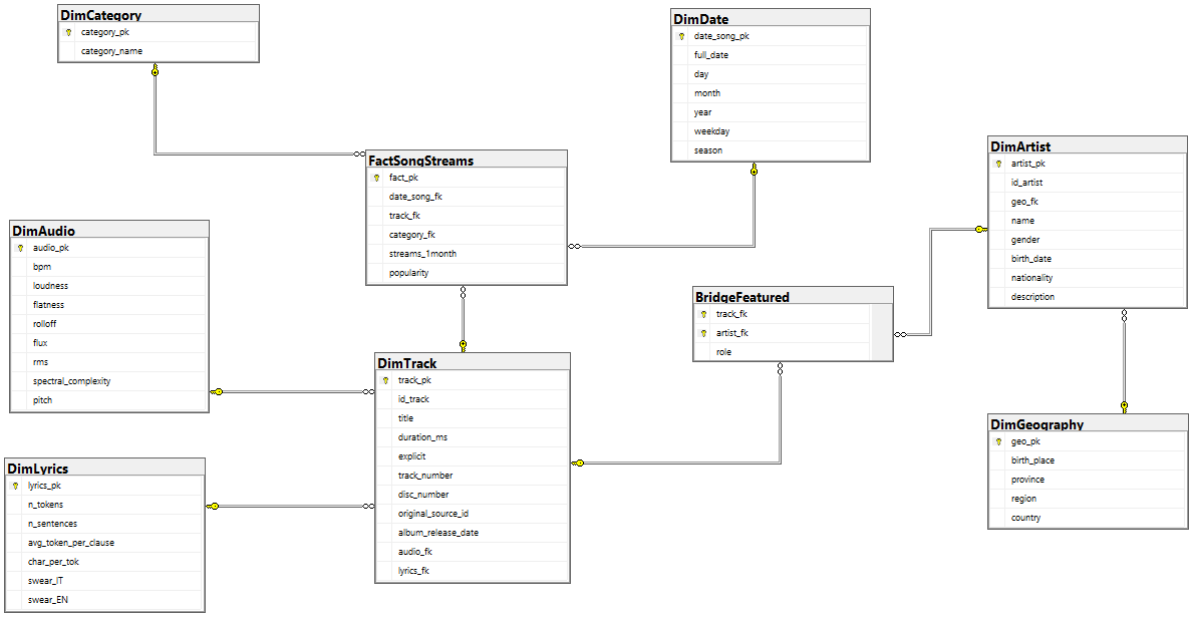

Figura 1: Snowflake Schema

3.1. Strategia di Modellazione Dimensionale (Assignment 4)

La definizione delle tabelle dimensionali ha seguito un approccio modulare.

Dimensioni di Lookup (Indipendenti) Queste tabelle sono collegate direttamente alla Fact Table e non presentano ulteriori ramificazioni.

- **DimDate:** Costituisce l'asse portante per le analisi temporali. La scelta della Primary Key (`date_song_pk`) nel formato intero *Smart Key* (`YYYYMMDD`) offre un duplice vantaggio: semplifica il confronto numerico migliorando l'indicizzazione rispetto ai formati data standard e garantisce l'ordinamento nativo per le aggregazioni OLAP.
- **DimCategory:** Ospita le macro-categorie musicali. Agisce come lookup deduplicato utilizzando una *surrogate key* per l'efficienza referenziale e vincoli di unicità per evitare duplicati semantici.

Dimensioni Normalizzate (Snowflaking) Le entità principali (Artista e Brano) sono state modellate sfruttando il principio dello *Snowflaking* per obiettivi architetturali distinti:

- **DimArtist (Gerarchia Geografica):** La tabella `DimArtist` è collegata alla dimensione `DimGeography`. Questa normalizzazione gestisce la relazione N:1 tra artisti e luoghi. Esternalizzare la geografia evita la ridondanza dei dati testuali nella tabella artisti e garantisce l'integrità referenziale, facilitando la manutenzione delle gerarchie territoriali.
- **DimTrack (Vertical Partitioning):** La tabella centrale `DimTrack` funge da hub per due dimensioni satellite, `DimAudio` (metriche tecniche) e `DimLyrics` (metriche testuali). Lo scopo primario è il **Vertical Partitioning**, ovvero segregare attributi pesanti e a bassa frequenza di accesso (come testi o dettagli tecnici) alleggerisce la dimensione principale, massimizzando le performance delle query che richiedono solo i dati anagrafici del brano.

3.1.1 Gestione delle Relazioni N:M (Analisi Comparativa)

La criticità modellistica principale ha riguardato la gestione dei "Featuring". Nel dominio musicale, la relazione tra *Brano* e *Artista* è intrinsecamente *Many-to-Many* (N:M).

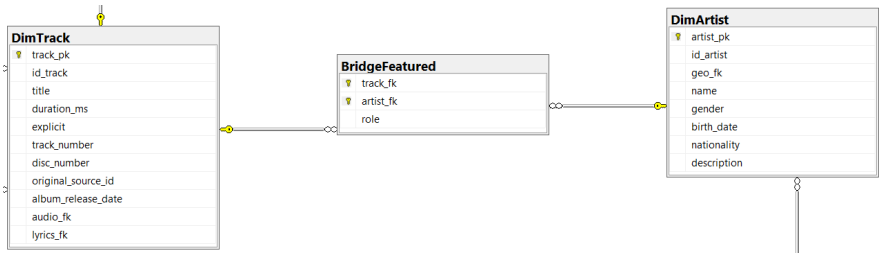

Figura 2: Relazione Many-to-Many tramite Bridge Table

Al fine di giustificare la scelta architetturale, è stata condotta un'analisi costi-benefici su tre approcci distinti:

Alternativa A: "Primary Artist Only"

Logica: Associare alla traccia solo il primo artista (Main). Scartata per perdita di informazioni. Questo approccio impedirebbe di analizzare l'impatto delle collaborazioni e sottostimerebbe il peso degli artisti che operano spesso in featuring.

Alternativa B: "Fact Table Explosion"

Logica: Creare una riga nella Fact Table per ogni coppia Brano-Artista. *Criticità:* Scartata per rischio di **Storage Redundancy** e **Double Counting**. Sommando gli stream totali, un brano con 3 artisti verrebbe conteggiato tre volte, falsando le aggregazioni globali.

Alternativa Adottata: Bridge Table

Si è optato per l'implementazione della tabella associativa `BridgeFeatured`. Questa struttura collega `DimTrack` e `DimArtist` preservando la granularità originale della Fact Table. I vantaggi chiave includono:

1. **Integrità della Misura:** La Fact Table mantiene una sola riga per brano, garantendo che le misure additive (stream) non siano duplicate fisicamente nello storage.
2. **Semantica del Ruolo:** L'attributo `Role` (BIT) arricchisce la relazione distinguendo semanticamente l'artista principale (`Main=1`) dai collaboratori (`Feat=0`).
3. **Flessibilità di Query:** Consente analisi bidirezionali (dal brano agli artisti e viceversa) tramite join standard, senza alterare la struttura dei fatti.

Trade-off: Si accetta un maggiore onere computazionale (join aggiuntive) in cambio della pulizia e della correttezza dello schema fisico.

3.1.2 Fact Table: FactSongStreams

Il nucleo dello schema è la `FactSongStreams`. La granularità del dato è definita a livello di singolo brano per singola data. Pertanto, l'unicità di ogni record nella Fact Table è garantita dalla **Composite Primary Key**, costituita dalla combinazione delle chiavi esterne dimensionali (`date_song_fk`, `track_fk`, `category_fk`). Di seguito le **Misure:**

- `streams_1month` (additiva): Rappresenta il volume d'ascolto.
- `popularity` (semi-additiva): Rappresenta lo score di tendenza.

Le misure ammettono valore `NULL` ad esempio in caso di assenza di rilevazione. Le Foreign Key, al contrario, sono vincolate a `NOT NULL` per garantire l'integrità referenziale.

3.2. Data Splitting (Assignment 5)

Si richiedeva la realizzazione di un programma Python in grado di suddividere i dataset *enriched* in più file separati, uno per ciascuna tabella del Data Warehouse progettato nello step precedente. Lo script implementa esattamente questa logica: a partire dai file puliti, genera tutti i CSV finali relativi alle dimensioni, alla bridge table e alla fact table, pronti per il caricamento.

3.2.1 Gestione dei file e struttura del codice

La lettura e la scrittura dei dati avvengono tramite il modulo standard `csv` in codifica UTF-8, così da gestire correttamente caratteri speciali presenti nei nomi degli artisti o nelle descrizioni testuali. Una volta caricati i file, il programma costruisce due dizionari di supporto, `a_idx` e `t_idx`, che associano a ogni nome di colonna il suo indice nel CSV. Questa scelta consente di accedere ai campi per nome (ad esempio `full_date` o `track_genre`) anziché per posizione numerica, migliorando la chiarezza e la manutenibilità del codice.

3.2.2 Logica generale di splitting

Il processo di splitting segue una logica bottom-up tipica dei Data Warehouse:

1. prima vengono create tutte le dimensioni indipendenti, tramite deduplicazione e assegnazione di chiavi surrogate;
2. successivamente vengono costruite le tabelle che dipendono da tali chiavi, cioè DimTrack, la bridge table e la fact table.

Un aspetto centrale dell'implementazione è la gestione esplicita dei valori mancanti. Per ciascuna dimensione viene introdotta una riga speciale con chiave primaria pari a `0`, che rappresenta il valore `Unknown`. Questa scelta vale per la dimensione geografica (`geo_pk = 0`), per la dimensione temporale (`date_song_pk = 0`) e per le dimensioni delle feature audio e lyrics (PK = 0). In questo modo si evitano foreign key nulle, si garantisce la coerenza referenziale e si rende possibile aggregare in modo esplicito i valori mancanti nelle analisi. Di seguito le varie dimensioni.

Dimensione geografica (DimGeography)

La prima dimensione generata è quella geografica. Scorrendo il file `artists_enriched.csv`, il programma raccoglie tutte le combinazioni uniche di `(birth_place, province, region, country)` e assegna a ciascuna un `geo_pk` progressivo, riservando il valore `0` alla combinazione completamente sconosciuta. Questa deduplicazione evita la ripetizione di informazioni geografiche e rende più efficienti e pulite le analisi territoriali.

Dimensione artista (DimArtist)

Per ogni artista viene assegnata una chiave surrogate `artist_pk` e viene mantenuto l'identificativo naturale `id_artist` (campo `id_author`) per garantire la tracciabilità con il dataset originale. La foreign key geografica `geo_fk` viene risolta tramite lookup nella DimGeography, oppure impostata a `0` in caso di informazioni mancanti. In parallelo, viene costruito il dizionario `artist_pk_lookup`, che mappa l'ID originale dell'artista alla relativa PK surrogate: questa struttura è fondamentale per collegare correttamente artisti e tracce nelle tabelle successive.

Dimensione categorie (DimCategory)

La dimensione delle categorie musicali viene derivata dal dataset `tracks_A3.csv`. Per ogni valore del campo `track_genre` viene creata una riga unica in DimCategory, assegnando un `category_pk`. Il dizionario `category_dict` (genere → PK) viene conservato per risolvere rapidamente la foreign key nella fact table, evitando di memorizzare stringhe testuali nella fact.

Dimensione temporale (DimDate)

La dimensione temporale viene costruita a partire dal campo `full_date`. Quando la data è

presente, la chiave primaria viene generata come intero nel formato `YYYYMMDD`, eliminando i trattini: in questo modo la stessa data produce sempre la stessa PK e la deduplicazione è naturale. In caso di data mancante, viene utilizzato il valore `0`. Oltre alla data completa, vengono memorizzati anche attributi già derivati nel dataset enriched, come giorno, mese, anno, weekday e stagione.

Dimensioni tecniche: Audio e Lyrics

Per migliorare la normalizzazione, le feature tecniche delle tracce vengono separate da DimTrack e organizzate in due dimensioni dedicate:

- **DimAudio**, che contiene feature spettrali e acustiche;
- **DimLyrics**, che raccoglie feature testuali

Per entrambe le dimensioni, ogni combinazione unica di feature riceve una PK progressiva, mentre la tupla completamente mancante è associata alla PK `0`. I dizionari `audio_lookup` e `lyrics_lookup` permettono di risolvere rapidamente le foreign key nella fase di costruzione di DimTrack.

Dimensione traccia (DimTrack)

La dimensione traccia viene creata assegnando a ogni brano una chiave surrogate `track_pk`, mantenendo anche l'ID naturale `id_track`. La tabella include gli attributi descrittivi principali (titolo, durata, explicit, track_number, disc_number, original_source_id, album_release_date) e le foreign key verso DimAudio e DimLyrics (`audio_fk` e `lyrics_fk`). In parallelo viene costruita la mappa `track_pk_lookup`, indispensabile per la bridge table e per la fact table.

Bridge table artista–traccia (BridgeFeatured)

La relazione many-to-many tra artisti e tracce viene modellata tramite la tabella BridgeFeatured.csv. Ogni riga rappresenta un legame tra una traccia e un artista, includendo il campo `role` per distinguere main artist (`role = 1`) e featured artist. Il main artist viene sempre inserito risolvendo la `artist_fk` tramite `artist_pk_lookup`. Per gli artisti featured, i nomi presenti nel campo `featured_artists` vengono risolti confrontandoli con quelli del dataset `artists_enriched.csv`, tramite una lookup `name_to_id` (nome → `id_author`) e la successiva mappatura verso la chiave surrogate `artist_pk`. Tuttavia, analizzando i risultati delle query successive, si è evidenziato un limite importante di questa strategia: i nomi dei featured nel dataset delle tracce non sempre coincidono esattamente con quelli del dataset artisti, poiché possono essere abbreviati o scritti in modo diverso. In questi casi il matching testuale fallisce e alcuni featured non vengono collegati nella bridge table. Un esempio è "Anna Pepe", che compare come *"anna pepe"* in un file e come *"anna"* nell'altro. Di conseguenza, la bridge risulta corretta ma non completamente esaustiva; per migliorarne la completezza sarebbe stato preferibile collegare i featured utilizzando la nomenclatura del *primary artist* nel dataset delle tracce, più stabile e coerente. Inoltre, sono stati deliberatamente esclusi dalla bridge tutti i featured non presenti nel dataset

`artists_enriched.csv`. La colonna dei featured conteneva infatti oltre 1000 nomi senza informazioni anagrafiche o geografiche: includerli avrebbe introdotto rumore e alterato in modo significativo le analisi. Per questo motivo, una collaborazione viene inserita solo se il nome del featured è risolvibile prima in un ID artista e poi in una PK surrogate.

Fact table (FactSongStreams)

Infine, viene costruita la `FactSongStreams`, che rappresenta la tabella dei fatti. Ogni riga contiene esclusivamente chiavi verso le dimensioni (`date_song_fk`, `track_fk`, `category_fk`) e le misure quantitative `streams_1month` e `popularity`. La data viene convertita nel formato `YYYYMMDD` (oppure `0` se mancante), mentre le altre foreign key vengono risolte tramite i dizionari di lookup. La fact risulta quindi pulita, compatta e perfettamente adatta alle successive analisi con SSIS e al popolamento del cubo OLAP.

3.3. Data uploading with Python (Assignment 6)

L'Assignment ha come obiettivo il popolamento del database `Group_ID_13_DB` a partire dai dati preparati negli assignment precedenti. A tal fine è stato sviluppato uno script Python che utilizza la libreria `pyodbc` per connettersi a SQL Server e caricare i file CSV presenti nella cartella `00_data/warehouse_ready`. Lo script gestisce esplicitamente la differenza tra tabelle con chiave primaria manuale e tabelle con chiave `IDENTITY`, evitando l'inserimento della PK quando necessario. Il caricamento segue un ordine coerente con i vincoli di integrità referenziale: prima le dimensioni di lookup, poi le dimensioni principali, successivamente la tabella bridge `BridgeFeatured` e infine la fact `FactSongStreams`. Per garantire robustezza e controllabilità, il codice utilizza commit separati per ogni tabella, messaggi di log sullo stato di avanzamento e una funzione di supporto per la lettura dei file CSV, rendendo il processo di popolamento corretto, ripetibile e adatto a operazioni di lunga durata.

4. ETL Implementation with SSIS

4.1. Data Warehouse Population Using SSIS (Assignment 7)

La fase iniziale (Assignment 7) ha riguardato la predisposizione di un ambiente di *Staging* parallelo e il caricamento di un dataset funzionale al testing delle successive logiche di calcolo. Preliminarmente, è stata eseguita una replica di tutte le tabelle del Data Warehouse, distinguendole tramite il suffisso `_SSIS` (es. `DimTrack_SSIS`). La creazione di questo ambiente "ombra" è risultata fondamentale per isolare l'attività di sviluppo ETL dai dati di produzione pre-caricati, permettendo l'esecuzione iterativa di test senza rischi per l'integrità del sistema.

4.1.1 Control Flow

Il design del pacchetto SSIS di popolamento è stato guidato dai vincoli fisici del database. Data la presenza di Foreign Key attive, non è tecnicamente possibile avviare il caricamento dalla Fact Table, in quanto ogni record figlio necessita della pre-esistenza del record genitore. Di conseguenza, il *Control Flow* è stato strutturato secondo una logica sequenziale a cascata.

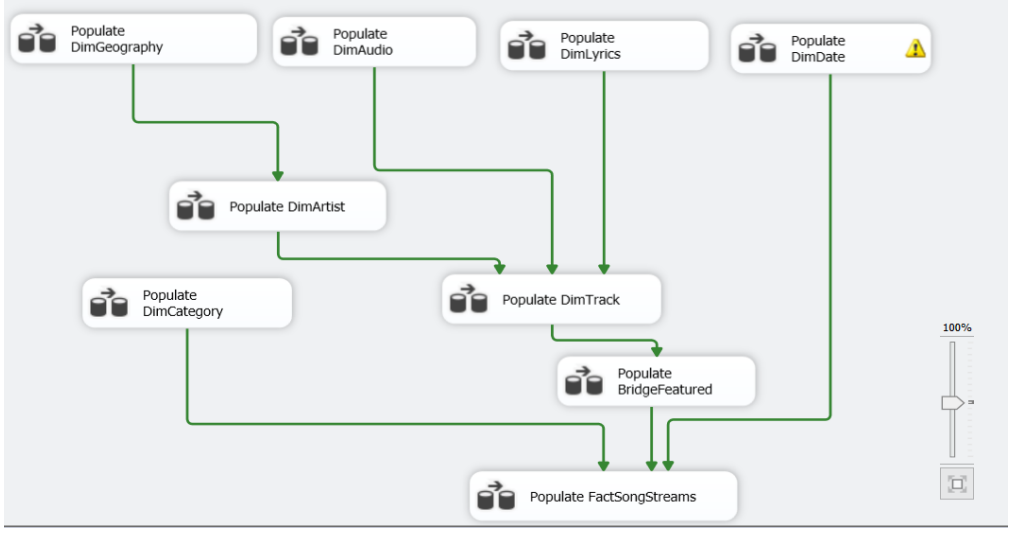

Figura 3: SSIS Control Flow

Come illustrato in Figura 3, il workflow implementa una logica di caricamento gerarchica, processando le dimensioni indipendenti prima di popolare le entità core e la Fact Table:

1. **Independent Dimensions:** Caricamento parallelo delle dimensioni di lookup (`Geography`, `Audio`, `Lyrics`, `Date`). In questa fase, per mitigare un'anomalia nei dati sorgente (presenza di record vuoti nel CSV Date), è stata implementata una logica di *Default Value Assignment* (data fittizia `1900-01-01`, `weekday=9`) per prevenire fallimenti su colonne `NOT NULL`.
2. **Dependent Dimensions:** Caricamento sequenziale di `DimArtist` e `DimTrack`, garantendo che le dipendenze geografiche e tecniche siano già soddisfatte.
3. **Bridge Table:** Popolamento della `BridgeFeatured`, subordinato al completamento delle anagrafiche Artisti e Tracce.
4. **Fact Table:** Caricamento finale di `FactSongStreams`, a chiusura della catena.

4.1.2 Sampling Strategy per l'Ottimizzazione del Testing

Al fine di agevolare le fasi successive di validazione e query testing, si è deciso di operare su un sottoinsieme rappresentativo dei dati (campionamento al 30%). Lavorare su volumi ridotti permette

infatti di verificare più rapidamente l'output delle trasformazioni complesse e di validare manualmente la correttezza delle aggregazioni. Tuttavia, l'applicazione di un campionamento casuale indiscriminato su tutte le tabelle si è rivelata impraticabile. I test preliminari hanno evidenziato una **disgiunzione insiemistica critica**: filtrando il 30% delle tracce e il 30% degli artisti in modo indipendente, la probabilità di intersezione (ovvero che una traccia campionata trovasse il proprio artista anch'esso campionato) risultava statisticamente irrilevante. Tale approccio ha prodotto una Fact Table quasi vuota (circa 9 record), rendendo il dataset inutile per qualsiasi verifica funzionale.

Per garantire la consistenza del Data Warehouse e la significatività dei test, è stata quindi adottata una strategia ibrida:

- **Dimensioni e Bridge (Full Load):** Tutte le tabelle anagrafiche sono state caricate al 100%. Questo assicura che la struttura dimensionale sia completa e coerente.
- **Fact Table (Filtered Load):** Il filtro del 30% (tramite *Percentage Sampling Transformation*) è stato applicato esclusivamente in ingresso alla `FactSongStreams`.

Questa configurazione assicura che il volume finale sia gestibile per le attività di debug, mantenendo al contempo la totale integrità referenziale e una distribuzione statistica degli stream coerente con il dataset originale.

4.2. Artist Production (Assignment 8)

L'obiettivo del data flow è ottenere, per ogni anno, l'elenco degli artisti ordinati in base al numero totale di brani pubblicati in quell'anno. Il flusso è stato costruito con due rami che vengono poi uniti: nel ramo sinistro si parte dalla fact table (source fact) per recuperare le informazioni sui brani e collegare l'anno tramite un Lookup sulla DimDate; dopo il lookup viene ordinato per track (chiave del brano) per prepararsi alla join. Nel ramo destro si parte dalla bridge (source bridge), che contiene l'associazione track–artist e l'indicatore di ruolo; anche qui viene ordinato per track, così da poter eseguire correttamente il Merge Join tra i due rami e ottenere per ogni brano sia l'anno sia gli artisti associati. A questo punto, si applica un Conditional Split selezionando solo i record con role == true ed escludendo i featured. Sui record filtrati si effettua una Lookup con la DimArtist per recuperare il nome dell'artista a partire dalla chiave. Infine si esegue un'Aggregazione (Group By) su (Year, ArtistName) calcolando Count(*) come TotalSongs, cioè il numero di brani pubblicati da quell'artista in quell'anno. Il risultato è stato poi ordinato per Year e TotalSongs in ordine decrescente (così, per ogni anno, gli artisti con più pubblicazioni compaiono per primi) e inviato in output verso una destinazione Flat File per la consegna finale.

4.3. Seasonality Score (Assignment 9)

L'obiettivo di questo flusso SSIS è calcolare, per ogni coppia *Country–Region* associata al *main artist*, due indicatori di stagionalità: il *SongScore*, che confronta il numero di brani pubblicati in estate e in inverno, e lo *StreamScore*, che confronta gli stream dopo un mese generati nelle due stagioni. Il data flow parte da *fact table* e *bridge table*, ordinate per *track* e unite tramite *Merge Join*. Dopo aver selezionato esclusivamente i *main artist*, i dati vengono arricchiti tramite *Lookup* sulle dimensioni temporale, artistica e geografica. Il flusso viene poi suddiviso in due rami in base alla stagione (estate e inverno), sui quali vengono calcolati, per ogni *Country* e *Region*, il numero di brani e il totale degli stream. I risultati vengono infine ricongiunti e utilizzati per calcolare gli indicatori di stagionalità, che sono esportati in un file flat finale. Per evitare errori di esecuzione, i casi in cui il denominatore risulta nullo vengono gestiti esplicitamente sostituendolo con un valore unitario. Inoltre, il risultato dei rapporti viene normalizzato a due cifre decimali per garantire uniformità nell'output. Infine, quando il valore dello score è inferiore a uno, viene aggiunto lo zero iniziale al fine di assicurare una rappresentazione numerica coerente e facilmente leggibile nel file flat di destinazione.Dall'analisi emerge che, per molte regioni, il *SongScore* è prossimo a 1, indicando una distribuzione bilanciata delle uscite tra estate e inverno. In alcuni casi, tuttavia, si osserva una maggiore concentrazione di pubblicazioni estive che non sempre si traduce in un aumento proporzionale degli stream, come evidenziato da valori di *StreamScore* inferiori a 1. I record con informazioni geografiche mancanti sono infine raccolti nella categoria *Unknown* e rappresentano un insieme marginale.

4.4. Analisi delle metriche regionali e per categoria musicale (Assignment 10)

L'Assignment ha come obiettivo l'analisi della distribuzione degli stream delle diverse macro-categorie musicali, definite nell'Assignment 3 (vedi sez. 2.4), in relazione alla regione di nascita del main artist. La richiesta dell'assignment consiste nel calcolare, per ciascuna categoria musicale e per ciascuna regione, un indicatore che confronti il peso degli stream attribuibili a quella regione con il peso degli stream attribuibili a tutte le altre regioni. Più precisamente, per ogni coppia (categoria, regione) si richiede il rapporto tra il numero cumulativo di stream dei brani di quella categoria il cui main artist è nato nella regione considerata e il numero totale di stream della stessa categoria associati ai main artist nati nelle altre regioni. Questo rapporto consente di misurare il grado di concentrazione geografica di una categoria musicale rispetto alle regioni di provenienza dei suoi artisti principali. Indicando con *streams_by_reg_cat* la somma degli stream dei brani appartenenti a una data categoria associati a main artist nati nella regione considerata, con *streams_by_cat* il totale degli stream della stessa categoria su tutte le regioni, e con *streams_other_regions* la somma degli stream della categoria nelle regioni diverse da quella considerata, il rapporto richiesto dall'Assignment 10 è quindi definito come:

$$\text{ratio} = \frac{\text{streams_by_reg_cat}}{\text{streams_other_regions}} = \frac{\text{streams_by_reg_cat}}{\text{streams_by_cat} - \text{streams_by_reg_cat}}$$

Impostazione iniziale del flusso

Il flusso ha origine da due sorgenti OLE DB distinte. La sorgente FACTSONG legge dalla fact table esclusivamente le colonne necessarie all'analisi: `track_fk`, `category_fk` e la misura `streams_1month`. Sono state volutamente escluse altre colonne non rilevanti per l'Assignment 10, così da ridurre il volume dei dati in transito e mantenere il flusso il più efficiente possibile. La sorgente BRIDGE legge invece dalla tabella di relazione brano–artista le colonne `track_fk`, `artist_fk` e `role`, che consentono di collegare ciascun brano agli artisti associati e di distinguere il ruolo dell'artista (main o featured). Come richiesto dal testo dell'Assignment 10, subito dopo la sorgente `BRIDGE` viene applicato un *Conditional Split* che seleziona esclusivamente i record relativi ai *main artist*, per i quali `role == TRUE`, escludendo tutti gli artisti featured. Prima di combinare le informazioni provenienti dalle due sorgenti, entrambi i flussi vengono ordinati tramite una trasformazione *Sort* sulla colonna `track_fk`, requisito necessario per l'utilizzo del *Merge Join*, che produce una vista unificata in cui ogni brano è associato al proprio main artist e al valore di stream. Il dataset integrato viene quindi arricchito tramite una sequenza di *Lookup* sulle dimensioni: il lookup **artist** recupera la chiave geografica `geo_fk` dalla dimensione artista, il lookup **category** associa a ciascun brano il nome della macro-categoria musicale (`category_name`), mentre il lookup **geography** utilizza `geo_fk` per ottenere gli attributi geografici `region` e `country`. L'inclusione esplicita del campo `country` è necessaria per distinguere correttamente le regioni `unknown` appartenenti a paesi diversi, evitando accorpamenti che altererebbero la coerenza geografica dell'analisi.

Fase di aggregazione e calcolo dell'indicatore

A questo punto il flusso contiene, per ogni brano, la categoria musicale, la regione (e il paese) di nascita del main artist e il valore di stream. Su questo dataset viene applicata una prima trasformazione *Aggregate*, che calcola `streams_by_reg_cat` come somma di `streams_1month` raggruppata per `(category_name, region, country)`, ottenendo il numero cumulativo di stream per ciascuna combinazione categoria–regione. L'output viene duplicato tramite un *Multicast*, così da calcolare in parallelo anche il totale degli stream per categoria senza ripetere le fasi precedenti del flusso. Su uno dei rami viene quindi applicata una seconda trasformazione *Aggregate*, che calcola `streams_by_cat` come somma di `streams_by_reg_cat` raggruppata per `category_name`, ottenendo il totale complessivo degli stream per ciascuna categoria su tutte le regioni. Prima di combinare i due risultati, entrambi i rami vengono ordinati tramite una trasformazione *Sort* su `category_name`, così da soddisfare i requisiti del successivo *Merge Join*. In questo modo, per ciascuna combinazione categoria–regione–paese risultano disponibili nello stesso record sia `streams_by_reg_cat` sia `streams_by_cat`. Successivamente, una trasforma-

zione *Derived Column* calcola le variabili necessarie alla metrica finale: `streams_other_regions`, ottenuta come differenza tra `streams_by_cat` e `streams_by_reg_cat`, e il rapporto `ratio`, calcolato coerentemente con la formulazione matematica precedentemente introdotta. La moltiplicazione per 1.0 nel numeratore e nel denominatore garantisce una divisione in virgola mobile, evitando troncamenti interi. Un ultimo *Sort* viene infine applicato per presentare i risultati in modo ordinato. Il risultato finale del *Data Flow* viene salvato tramite una *Flat File Destination* in un file CSV (`Assignment10_output.csv`), che contiene una riga per ciascuna combinazione `(country, region, category)` e riporta `streams_by_reg_cat`, `streams_by_cat`, `streams_other_regions` e il valore finale di `ratio`.

4.5. Advanced Artist Statistics (Assignment 11)

Impostazione iniziale del flusso

Il flusso SSIS dell'Assignment 11 parte da un *OLE DB Source* collegato alla tabella `Bridge`, che rappresenta la relazione molti-a-molti tra canzoni e artisti e contiene l'informazione chiave relativa al ruolo dell'artista nel brano (*main artist* o *featured artist*). La scelta di partire dalla tabella `Bridge` invece che dalla `Fact` è stata deliberata e motivata da due aspetti principali.In primo luogo, il ruolo dell'artista rappresenta l'elemento discriminante dell'analisi: partire dalla `Bridge` consente una suddivisione immediata del flusso in base al ruolo, garantendo una gestione chiara e coerente dei due casi (*main* e *featured*). In secondo luogo, partire dalla `Fact` ed effettuare un *lookup* verso la `Bridge` avrebbe richiesto la gestione di chiavi duplicate, poiché più righe della `Bridge` possono essere associate alla stessa canzone a causa delle collaborazioni. Il componente *Lookup* di SSIS non è adatto a gestire correttamente relazioni uno-a-molti, con il rischio di produrre risultati incompleti o non deterministici. Partendo invece dalla `Bridge` ed effettuando un *lookup* verso la `Fact` (relazione uno-a-uno sulla canzone), questo problema viene completamente evitato. Subito dopo la sorgente è stato inserito un *Conditional Split* basato sull'attributo `role`, che divide il flusso in due rami distinti: uno dedicato ai *main artist* e uno ai *featured artist*. Questa separazione è fondamentale poiché le metriche di trending seguono regole differenti nei due casi.

Ramo Main Artist

Nel ramo dei *main artist* viene eseguito un *Lookup* verso la tabella `Fact` per recuperare il numero di stream a un mese dalla pubblicazione. Per il calcolo delle metriche di trending è necessario determinare, per ciascun artista, sia la media degli stream delle proprie canzoni sia il numero totale di canzoni pubblicate come main artist. A questo scopo è stato utilizzato un componente *Multicast* che duplica il flusso: un ramo è destinato all'aggregazione per artista per calcolare la media degli stream e il conteggio delle canzoni, mentre l'altro ramo mantiene il dettaglio a livello di singola canzone. I risultati dell'aggregazione vengono ordinati per artista e successivamente riuniti al flusso

originale tramite un *Merge*, consentendo di arricchire ogni canzone con le statistiche complessive del proprio artista. Dopo il *Merge*, un *Conditional Split* separa gli artisti con più di una canzone da quelli con una sola canzone. Questa distinzione è necessaria poiché il calcolo della deviazione standard non è statisticamente significativo quando il numero di osservazioni è pari a uno.

Ramo main Artist con più di una canzone

Per gli artisti con più di una canzone, la deviazione standard degli stream viene calcolata esplicitamente all'interno del flusso SSIS seguendo la definizione matematica. Per ogni canzone viene calcolata la differenza al quadrato tra il numero di stream e la media dell'artista:

$$(streams - \mu_{artist})^2$$

Tali valori vengono poi aggregati per artista per calcolarne la somma, mentre il numero di canzoni viene recuperato tramite un'aggregazione di massimo. La std è quindi calcolata come:

$$\sigma_{artist} = \sqrt{\frac{\sum(streams - \mu)^2}{n}}$$

Le statistiche ottenute vengono riunite al flusso principale tramite *Merge*. Utilizzando la media e la deviazione standard specifiche dell'artista, vengono definiti due flag: una canzone è classificata come trending se $streams \geq \mu + \sigma$, mentre è classificata come flopping se $streams \leq \mu - \sigma$. Questo approccio consente di individuare esclusivamente scostamenti statisticamente significativi rispetto alla performance media dell'artista. Un ulteriore *Multicast* viene utilizzato per contare, per ciascun artista, il numero di canzoni trending e flopping e per calcolare le metriche finali:

$$Trending\ Percentage = 100 \cdot \frac{trending}{n}$$

$$Trending\ Factor = \frac{trending - flopping}{n}$$

Queste metriche vengono memorizzate per ciascun artista nel ruolo di main artist.

Ramo Featured Artist

Il ramo dei *featured artist* viene gestito separatamente. In questo caso, una canzone viene considerata trending per l'artista featured solo se risulta trending anche per il main artist, in accordo con le specifiche dell'assignment. Di conseguenza, questo ramo sfrutta direttamente i flag di trending calcolati nel ramo main. Anche in questo caso vengono calcolati Trending Percentage e Trending Factor, e i risultati vengono successivamente uniti a quelli dei main artist nella tabella finale.

Edge case: artisti con una sola canzone

Per gli artisti con una sola canzone non è possibile calcolare la deviazione standard. L'assignment richiede quindi un confronto con una media globale basata sulle prime canzoni pubblicate dagli altri artisti. Per calcolare questo riferimento globale, il flusso unisce tutti i main artist con gli artisti

che hanno una sola canzone ed esclude i record associati alla data speciale 0, che rappresenta una data fittizia utilizzata per canzoni prive di informazioni temporali. L'inclusione di tale data avrebbe compromesso l'identificazione delle reali canzoni di debutto. Per ciascun artista viene selezionata la prima data di pubblicazione valida; nel caso in cui più canzoni condividano la stessa data minima (ad esempio album che contiene tante canzoni pubblicate nello stesso giorno), viene scelta la canzone con il numero massimo di stream. Su queste canzoni viene quindi calcolata la media globale degli stream. Nel dataset in esame questo ramo non ha prodotto risultati, poiché non sono presenti artisti con una sola canzone. Tuttavia, il ramo dedicato agli edge case è stato comunque implementato e indirizzato verso una destinazione separata, al fine di evitare l'introduzione di colonne inutilmente valorizzate a `NULL` nella tabella principale. Questa scelta preserva la chiarezza semantica, mantiene il dataset finale pulito e rende il flusso modulare ed estendibile nel caso in cui in futuro il dataset includa tali artisti.

Output finale

Tutti i rami relativi ai *main* e ai *featured artist* convergono in una tabella finale che riporta, per ciascun artista, il Trending Percentage e il Trending Factor sia come main artist sia come featured artist. I risultati mostrano che, all'aumentare del numero di canzoni pubblicate, la Percentage tende a diminuire, mentre il Factor si avvicina allo zero, indicando un equilibrio tra brani di successo e brani sotto-performanti. Al contrario, artisti con una produzione più contenuta presentano spesso valori di trending più elevati, suggerendo una maggiore concentrazione di canzoni che performano al di sopra della propria media. Nel complesso, le metriche introdotte consentono una valutazione più informativa delle performance degli artisti rispetto al numero di stream.

4.6. Business Insight: analisi dell'impatto stagionale (Assignment 12)

Query Definition:

In accordo con la consegna dell'Assignment 12, che richiedeva la definizione autonoma di una query da implementare in SSIS, è stata progettata un'analisi volta a studiare l'interazione tra **stagionalità di pubblicazione**, **età dell'artista** e **categoria musicale**, con l'obiettivo di individuare le combinazioni *fascia d'età* × *categoria* × *stagione* più favorevoli in termini di stream. L'analisi si basa sull'ipotesi che il successo di un brano dipenda anche dal periodo dell'anno in cui viene pubblicato, oltre che dalle sue caratteristiche musicali e dall'artista. Gli artisti sono stati suddivisi in tre fasce d'età (0–28, 29–40, 40+); per ciascuna fascia, categoria musicale e stagione di pubblicazione è stato calcolato un indicatore di *Seasonal Impact*, definito come il rapporto tra gli stream medi dei brani pubblicati in una determinata stagione e quelli degli stessi brani appartenenti alla medesima combinazione categoria e fascia d'età ma pubblicati nelle altre stagioni. Un valore superiore a 1 indica una stagione favorevole, mentre un valore inferiore a 1 segnala una stagione penalizzante. Per

ciascuna fascia d'età viene quindi individuata la combinazione categoria–stagione che massimizza il valore di *Seasonal Impact*. Dal punto di vista business, questa analisi fornisce indicazioni operative utili alla pianificazione delle uscite discografiche e delle strategie di promozione, consentendo di ottimizzare il timing delle pubblicazioni e l'allocazione degli investimenti di marketing. L'indicatore è stato infine calcolato utilizzando le medie degli stream anziché le somme, così da ottenere una misura più stabile e meno influenzata da singoli brani con valori eccezionalmente elevati.

SSIS Solution:

Il flusso SSIS dell'Assignment 12 parte dalla `FactSongStreams`, da cui vengono estratte la chiave della traccia (`track_fk`), la chiave di categoria (`category_fk`), la chiave temporale (`date_song_fk`) e la misura `streams_1month`. In parallelo viene letta la `BridgeFeatured`, contenente le associazioni tra tracce e artisti e l'attributo `role`. Le due sorgenti, ordinate per `track_fk`, vengono unite tramite un *Merge Join* e successivamente filtrate con una *Conditional Split* per mantenere esclusivamente i *main artist* (`role = TRUE`).

Il flusso viene quindi arricchito tramite una sequenza di *Lookup*:

- `DimArtist`, per recuperare la data di nascita (`birth_date`);
- `DimCategory`, per associare il nome della macro-categoria musicale;
- `DimDate`, per ottenere la data di pubblicazione e la stagione (`season`).

Una successiva *Conditional Split* esclude i record con valori di default per la data di nascita (`1900-01-01`) o per la chiave temporale (`date_song_fk = 0`), garantendo l'affidabilità delle informazioni temporali. Infine, tramite due *Derived Column*, viene calcolata l'età dell'artista al momento della pubblicazione e assegnata la relativa fascia d'età, utilizzata come dimensione di segmentazione nell'analisi. A partire dal dataset arricchito, il flusso viene duplicato tramite un *Multicast* per calcolare separatamente le statistiche stagionali e quelle complessive necessarie alla costruzione dell'indicatore di *Seasonal Impact*.

Nel primo ramo, una trasformazione *Aggregate* (`aggr Season`) raggruppa i dati per fascia d'età, categoria musicale e stagione, calcolando la somma degli stream stagionali e il numero di brani, da cui viene derivata la media stagionale. In parallelo, il secondo ramo applica una seconda *Aggregate* (`aggr all season`) che raggruppa i dati per fascia d'età e categoria musicale, ignorando la stagione, e calcola la performance media complessiva della categoria.

I due flussi aggregati vengono ordinati sulle chiavi comuni (`age_group`, `category_name`) e uniti tramite *Merge Join*. Una successiva *Conditional Split* (`check there are other season`) seleziona esclusivamente le combinazioni per cui esistono brani pubblicati in più stagioni, escludendo i casi in cui il confronto stagionale non sarebbe significativo.

Una *Derived Column* calcola le medie degli stream della stagione corrente e delle altre stagioni:

$$\texttt{avg_season} = \frac{\texttt{sum_stream_season}}{\texttt{count_stream_season}}$$

$$\texttt{avg_other_season} = \frac{\texttt{sum_streams_allSeason} - \texttt{sum_stream_season}}{\texttt{count_streams_allSeason} - \texttt{count_stream_season}}$$

In seguito, una seconda *Derived Column* calcola l'indicatore di *Seasonal Impact*:

$$\texttt{Seasonal Impact} = \frac{\texttt{avg_season}}{\texttt{avg_other_season}}.$$

Il flusso viene quindi duplicato tramite un secondo *Multicast*. Nel primo ramo una *Aggregate* (`max seasonal impact`) individua, per ciascuna fascia d'età, il valore massimo dell'indicatore; nel secondo ramo viene mantenuto il dettaglio completo delle combinazioni `(age_group, category_name, season)`. Dopo un ordinamento sulle chiavi comuni, un *Merge Join* consente di associare a ciascun massimo la combinazione categoria–stagione corrispondente. Una Conditional Split finale (best combination) seleziona infine solo le righe in cui il valore di Seasonal Impact coincide con il massimo della fascia d'età.

L'output finale riporta, per ciascuna fascia d'età, la combinazione categoria musicale–stagione che massimizza il *Seasonal Impact*: `URBAN` in `summer` per la fascia `0-28`, `SOFT POP` in `autumn` per la fascia `29-40` e `POP` in `autumn` per gli artisti `40+`. Valori dell'indicatore superiori a 1 indicano una stagione che amplifica significativamente le performance medie.

4.7. Valutazione degli Artisti e Strategie di Portafoglio (Assignment 13)

Query Definition:

L'obiettivo dell'Assignment 13 è fornire un supporto analitico alle decisioni di investimento di una record label, integrando le performance di streaming degli artisti con una visione strutturata del portafoglio complessivo. L'analisi non si limita a individuare gli artisti più performanti in termini di stream, ma mira a valutare il loro ruolo strategico all'interno del catalogo, considerando il rischio legato alla dipendenza da singoli successi e il livello di popolarità.

SSIS Solution:

Il flusso SSIS parte da una sorgente OLE DB collegata alla bridge table artista–traccia, necessaria per gestire correttamente la relazione molti-a-molti. Poiché l'artista rappresenta l'unità di investimento, viene applicata una suddivisione condizionale per selezionare esclusivamente i record in cui l'artista ricopre il ruolo di main artist, evitando di attribuire stream derivanti da featuring. I record così filtrati vengono poi arricchiti tramite una lookup con la fact table (vedi subsec.4.5) contenente gli stream al primo mese. Successivamente viene applicata un'aggregazione per artista, attraverso

la quale vengono calcolati il massimo degli stream al primo mese, la media degli stream per traccia, il totale degli stream al primo mese, il numero di tracce pubblicate e la popolarità media. Queste misure permettono di descrivere sia la performance complessiva dell'artista sia la distribuzione del successo all'interno del suo catalogo. A partire da tali aggregazioni viene definita la variabile hit_dependency, calcolata come rapporto tra il massimo degli stream e la media degli stream per traccia. Questo indicatore misura quanto il successo dell'artista sia concentrato su una singola hit rispetto alla performance media del catalogo. In parallelo, la popolarità media viene normalizzata dividendo il valore per 100, rendendola utilizzabile in modo coerente nei successivi passaggi decisionali. Sulla base della hit_dependency, gli artisti vengono classificati in tre profili distinti: Hit-Driven, quando il successo è fortemente concentrato su pochi brani; Catalog-Driven, quando il valore è distribuito su molte tracce; e Mixed, che rappresenta una situazione intermedia. Questa classificazione introduce una prima segmentazione strutturale del catalogo.

Ramo destro – Analisi di rischio e caratteristiche del singolo artista

Nel ramo destro l'analisi rimane focalizzata sul singolo artista. A partire dalla popolarità media viene definita una popularity band, utilizzando le seguenti soglie esplicite: Low se $avg_popularity < 40$, Medium se $40 \leq avg_popularity < 70$, High se $avg_popularity \geq 70$. Questa discretizzazione consente di trasformare una misura continua in classi facilmente interpretabili dal punto di vista manageriale. Incrociando l'artist profile con la popolarità media viene poi calcolata la variabile $portfolio_risk$, che sintetizza il rischio associato all'artista secondo le seguenti regole: Hit-Driven con $avg_popularity < 40$ (Viral Risk), Hit-Driven con $avg_popularity \geq 40$ (Superstar Potential), Catalog-Driven con $avg_popularity \geq 70$ (Evergreen Asset), Catalog-Driven con $avg_popularity < 40$ (Weak Catalog), Mixed con $avg_popularity \geq 50$ (Growth Candidate), mentre tutti gli altri casi vengono classificati come Standard Portfolio. Il portfolio risk permette di distinguere artisti con forte potenziale ma alta volatilità, artisti stabili e consolidati, e artisti che rappresentano un rischio maggiore dal punto di vista dell'investimento.

Ramo sinistro – Analisi di portafoglio e strategia della label

Nel ramo sinistro l'attenzione si sposta dal singolo artista al portafoglio complessivo della label. Gli artisti vengono suddivisi in tre rami distinti in base all'artist profile (Hit-Driven, Mixed, Catalog-Driven) e, per ciascun ramo, viene applicata un'aggregazione che calcola il numero di artisti presenti, la somma degli stream al primo mese, la media della hit dependency, la media degli stream e la media della popolarità. I tre flussi aggregati vengono poi ricombinati tramite una Union All, scelta necessaria perché i profili sono insiemi disgiunti e non esiste rischio di duplicazione dei record. In termini concettuali, questo passaggio equivale a una `UNION ALL` in SQL, che concatena i risultati dei diversi profili mantenendo tutte le righe; l'uso di una semplice `UNION` sarebbe stato semanticamente scorretto e computazionalmente più costoso. Dopo l'unione, il flusso viene ulteriormente articolato per calcolare il totale degli stream della label, ottenuto come somma dei flussi

aggregati dei tre profili. Attraverso l'uso di chiavi fittizie e di un merge, questo valore globale viene associato a ciascun profilo, consentendo il calcolo della $portfolio_share$, definita come il rapporto tra gli stream del profilo e il totale della label. Sulla base della portfolio share viene poi definita la $profile_strategy$, secondo le seguenti soglie: Core Investment se $portfolio_share \geq 0.5$, Selective Investment se $0.2 \leq portfolio_share < 0.5$, Maintenance se $portfolio_share < 0.2$. Questa strategia sintetizza il ruolo di ciascun profilo all'interno del catalogo complessivo.

Integrazione finale e decisione di investimento

I risultati del ramo sinistro e del ramo destro vengono ricongiunti tramite un merge sull'*artist profile*. Per ciascun artista viene quindi calcolato l'*artist investment score*, definito come `total_streams` × `portfolio_share`. Questa misura combina la performance individuale con il peso strategico del profilo di appartenenza, consentendo un confronto coerente tra artisti appartenenti a cluster diversi. Sulla base dello score vengono definite tre classi di priorità di investimento: *High Priority* per valori $\geq$ 1,000,000, *Medium Priority* per valori compresi tra 300,000 e 1,000,000, e *Low Priority* per valori inferiori a 300,000. La query produce così una raccomandazione operativa chiara, utile per l'allocazione delle risorse della record label.

I risultati mostrano una forte concentrazione del valore sugli artisti *Hit-Driven*, che generano la maggior parte degli stream nel primo mese e sono classificati come investimenti prioritari. All'interno di questo gruppo emergono sia artisti con *Superstar Potential*, caratterizzati da elevata popularity e buone prospettive di continuità, sia artisti *Viral Risk*, con performance molto elevate ma meno stabili nel lungo periodo. Gli artisti *Mixed* occupano una posizione intermedia, contribuendo in modo equilibrato agli stream complessivi e venendo gestiti con una strategia di *Maintenance*. Gli artisti *Catalog-Driven*, infine, presentano un peso economico ridotto e sono generalmente classificati come *Low Priority*, svolgendo principalmente un ruolo di ampliamento del catalogo piuttosto che di generazione diretta di ricavi.

5. OLAP Cube Design

In questa fase, l'attenzione si è spostata dall'architettura relazionale all'analisi multidimensionale. È stato progettato e implementato un cubo OLAP (*Online Analytical Processing*) basato su Microsoft SQL Server Analysis Services (SSAS), con l'obiettivo di abilitare interrogazioni rapide e navigazione gerarchica sui dati aggregati.

5.1. Cube Structure (Assignment 14)

La struttura del cubo ricalca lo Snowflake Schema definito nel Data Warehouse, introducendo però astrazioni logiche necessarie per supportare le esigenze di navigazione *drill-down* e *roll-up*.

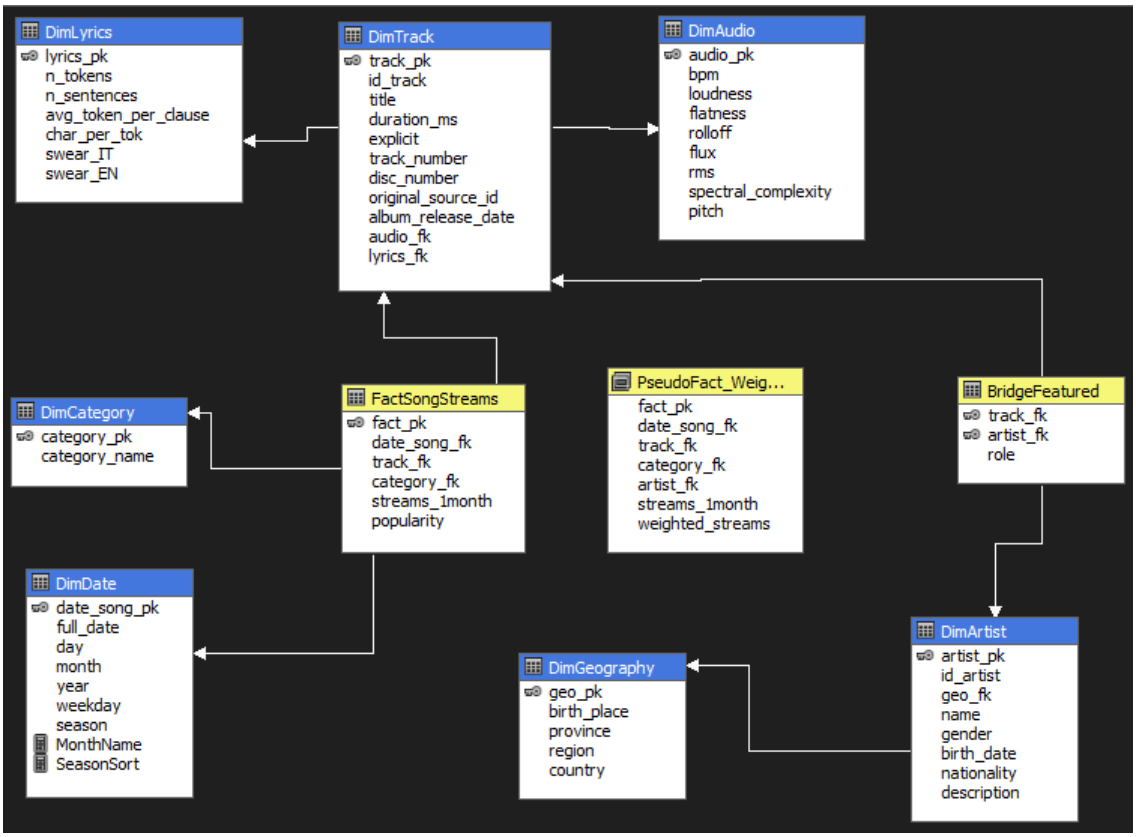

Figura 4: Data Source View

5.1.1 Dimensions and Hierarchies

Le dimensioni sono state arricchite con gerarchie utente esplicite per facilitare l'analisi a diversi livelli di granularità:

- **DimDate (Calendar Hierarchy):** È stata definita una gerarchia temporale naturale `Year` → `Month` → `Day`. Questo permette agli analisti di aggregare istantaneamente gli stream per anno e scendere progressivamente fino al dettaglio giornaliero per identificare pattern stagionali.
- **DimGeography (Geo Hierarchy):** Implementa la gerarchia spaziale `Country` → `Region` → `Province`. Questa struttura è essenziale per le analisi di distribuzione territoriale, permettendo di visualizzare la popolarità degli artisti dal livello nazionale fino a quello locale.
- **Vertical Partitioning:** Le dimensioni `DimAudio` e `DimLyrics`, pur mantenendo indipendenza logica, sono collegate alla `DimTrack` per permettere operazioni di "slice" basate su caratteristiche tecniche (es. filtrare brani con alti BPM o specifiche metriche testuali).

5.1.2 Measures

Nel *Measure Group* principale (`Fact Song Streams`), sono state definite le metriche core:

- **Streams:** Misura pienamente additiva lungo tutte le dimensioni.
- **Popularity:** Misura semi-additiva. Poiché la popolarità è uno snapshot puntuale, la somma non ha validità analitica.

5.2. Advanced Modeling: PseudoFact e Weighted Analysis

La sfida progettuale più complessa ha riguardato l'implementazione della logica di ripartizione richiesta dall'Assignment 16: calcolare il contributo medio degli artisti ponderando gli stream in base al ruolo (*0.8 per Main Artist, 0.2 per Featured*). L'approccio standard per le relazioni Many-to-Many in SSAS comporta che il valore intero del fatto venga associato a tutti i membri della dimensione. Per ottenere un valore ponderato sarebbe necessario ricorrere a script complessi che degradano le performance al crescere del dataset. Per ovviare a ciò, si è optato per una soluzione strutturale: la creazione del Measure Group specializzato `PseudoFact Weighted Streams`.

Integrazione tramite Dimension Usage Sebbene a livello di Data Source View (Figura 4) l'entità possa apparire priva di connettori grafici espliciti (trattandosi di una tabella derivata logica), essa è stata pienamente integrata nel cubo tramite il pannello **Dimension Usage**.

	Measure Groups		
Dimensions	Fact Song Streams	Bridge Featured	Pseudo Fact Weighted Strea...
DimDate	Date Song Pk		Date Song Pk
DimCategory	Category		Category
DimTrack	Track	Track	Track
DimArtist	Bridge Featured	Artist	Artist
DimAudio	DimTrack		
DimGeography	Bridge Featured	DimArtist	
DimLyrics	DimTrack		

Figura 5: Dimension Usage

Come dimostrato in Figura 5, la `PseudoFact` (ultima colonna) interseca correttamente tutte le dimensioni chiave:

1. **DimTrack e DimArtist:** Per identificare univocamente la coppia brano-autore.
2. **DimDate e DimCategory:** Per permettere l'analisi temporale e per genere anche sui dati ponderati, rendendo la PseudoFact navigabile esattamente come la Fact principale.

Vantaggi della Soluzione Questa architettura trasforma un complesso problema di algebra relazionale in una semplice operazione additiva. I vantaggi chiave sono:

- **Performance (Pre-computation):** Il calcolo oneroso dei pesi viene eseguito a monte, garantendo tempi di risposta immediati sulle dashboard.
- **Gestione della Ripartizione (Allocation):** A differenza del comportamento standard delle relazioni N:M in SSAS (che attribuiscono il valore intero del fatto a ciascun membro), la PseudoFact permette di assegnare quote specifiche.
- **Precisione Analitica:** Questo approccio è l'unico che consente di calcolare medie annuali ponderate senza incorrere in distorsioni matematiche dovute alla sovrapposizione degli stream tra artisti collaboratori.

6. MDX Analysis

6.1. Stream mensili per regione (Assignment 15)

La query è stata costruita introducendo una misura calcolata tramite l'istruzione `WITH MEMBER`, denominata `totCountry`, che calcola dinamicamente il totale degli stream a livello di paese per ciascun mese. Il valore è ottenuto sommando gli stream di tutte le regioni figlie del paese associato al membro geografico corrente, utilizzando le funzioni `ancestor` e `descendants` sulla gerarchia `Geography`, così da mantenere coerenza con il contesto temporale e geografico della riga analizzata.

```
WITH MEMBER totCountry AS
  Sum(
    Descendants(
      Ancestor( [DimGeography].[Geography].CurrentMember, [DimGeography].[Geography].[Country] ),
      [DimGeography].[Geography].[Region]
    ),
    [Measures].[Streams 1month]
  )

SELECT
  { [Measures].[Streams 1month], totCountry } ON COLUMNS,
  NonEmpty(
    (
      [DimDate].[Year].[Year],
      [DimDate].[Calendar].[Month],
      [DimGeography].[Country].[Country],
      [DimGeography].[Geography].[Region]
    ),
    [Measures].[Streams 1month]
  ) ON ROWS
FROM [Group_ID_13_DSV]
```

Listing 1: Monthly Streams By Region

Nel blocco `SELECT`, la misura `Streams 1month` e la misura calcolata `totCountry` sono riportate sulle colonne, mentre sulle righe viene definita una combinazione di dimensioni temporali (`Year`, `Month`) e geografiche (`Country`, `Region`). L'uso di `NONEMPTY` consente di mostrare esclusivamente le combinazioni che presentano valori di stream. Sono stati inoltre mantenuti i casi con `Year = 0` e gli attributi geografici `Unknown`. In particolare, il caso `Unknown-Unknown` identifica esplicitamente stream associati a un paese sconosciuto e viene mantenuto separato dalle aggregazioni nazionali, evitando che tali valori influenzino il calcolo `totCountry` per i paesi noti.

Year	Month	Country	Region	Streams 1month	totCountry
0	–	Italy	Calabria	4 243	774 019
0	–	Italy	Lazio	156 724	774 019
0	–	Italy	Unknown	278 007	774 019
0	–	Unknown	Unknown	332 540	332 540
1992	February	Italy	Piemonte	4 912	4 912
1993	January	Italy	Lombardia	4 183	4 183
1993	January	Unknown	Unknown	15 090	15 090

Tabella 1: Esempio di output della query MDX: stream mensili per regione e totale nazionale

6.2. Stream ponderati degli artisti (Assignment 16)

La query definisce tre misure calcolate tramite `WITH MEMBER`. `GrandTotalStreams_Year` calcola il totale annuale degli stream aggregando la misura `Streams 1month` sull'insieme di tutti gli artisti, fornendo così il volume complessivo di stream per ciascun anno.

La misura `WeightedArtistStreams_Year` utilizza la misura `Weighted Streams`, introdotta a livello di cubo come scelta progettuale per garantire maggiore efficienza e coerenza del modello. Tale misura incorpora direttamente la pesatura tra *main artist* (0.8) e *featured artist* (0.2), permettendo di riutilizzare la stessa logica di calcolo in diverse analisi senza doverla ridefinire in ogni query MDX. A partire da queste due misure viene infine calcolata `AvgYearlyArtistStreams`, definita come il rapporto tra `WeightedArtistStreams_Year` e `GrandTotalStreams_Year`. Questo indicatore esprime il contributo medio ponderato degli artisti rispetto al totale annuale degli stream.

Nel blocco `SELECT`, le misure sono visualizzate sulle colonne, mentre le righe sono definite dalla dimensione temporale `Year`, escludendo il membro speciale `Year = 0`. Tale scelta evita di includere un anno di default non confrontabile con gli anni reali, rendendo l'analisi più chiara e interpretabile.

```
WITH
  MEMBER GrandTotalStreams_Year AS
    ( [DimArtist].[Artist].[All], [Measures].[Streams 1month] )
  MEMBER WeightedArtistStreams_Year AS
    ( [DimArtist].[Artist].[All], [Measures].[Weighted Streams] )
  MEMBER AvgYearlyArtistStreams AS
    WeightedArtistStreams_Year / GrandTotalStreams_Year

SELECT
  { WeightedArtistStreams_Year, GrandTotalStreams_Year, AvgYearlyArtistStreams } ON COLUMNS,
  Filter(
    [DimDate].[Year].[Year],
    [DimDate].[Year].CurrentMember.Name <> "0"
  ) ON ROWS
FROM [Group_ID_13_DSV]
```

Listing 2: Weighted Artist Streams

Year	WeightedArtistStreams_Year	GrandTotalStreams_Year	AvgYearlyArtistStreams
1992	12 495.2	15 619	0.800
1993	130 157.0	161 216	0.807
1994	101 320.0	126 650	0.800
1995	7 830.4	9 788	0.800
1996	339 641.2	420 671	0.807
1997	84 648.8	105 811	0.800
1998	388 395.6	482 740	0.805
1999	259 064.6	319 096	0.812

Tabella 2: Esempio di output della query MDX: indicatore AvgYearlyArtistStreams per anno

6.3. Trend annuali delle categorie musicali (Assignment 17)

La query è stata impostata definendo innanzitutto una misura calcolata `Streams_prevYear` tramite l'istruzione `WITH MEMBER`, con l'obiettivo di recuperare, per ciascuna categoria musicale e per ciascun anno, il valore degli stream riferito all'anno precedente. Il valore viene ottenuto utilizzando `PrevMember` sulla gerarchia `Year` della dimensione temporale e mantenendo la misura `Streams 1month`. Tuttavia, nel caso in cui l'anno precedente corrisponda al valore speciale `Year = 0`, la misura viene forzata a `NULL`. Questa scelta evita di trattare il valore di default come un anno reale di confronto, preservandone il significato di dato non temporale. Successivamente viene definita la misura `percChange`, che calcola la variazione percentuale degli stream rispetto all'anno precedente. Il calcolo viene effettuato come rapporto tra la differenza degli stream correnti e quelli dell'anno precedente e il valore degli stream dell'anno precedente. Nel caso in

cui `Streams_prevYear` sia vuoto o nullo, il risultato viene esplicitamente impostato a `"no info"`, rendendo chiaro che il confronto non è disponibile. La presenza del valore `"no info"` è mantenuta anche per l'anno 1992, nonostante tecnicamente l'anno precedente possa essere individuato come `Year = 0`. Questa scelta è intenzionale: l'anno 0 rappresenta una data di default e non un vero riferimento temporale, pertanto è stato ritenuto più corretto segnalare l'assenza di informazioni piuttosto che produrre una variazione percentuale potenzialmente fuorviante.

```
WITH
  MEMBER Streams_prevYear AS
    IIF( [DimDate].[Year].CurrentMember.PrevMember.Name = "0", NULL,
       ( [DimDate].[Year].PrevMember, [Measures].[Streams 1month] )
    )

  MEMBER percChange AS
    IIF( IsEmpty(Streams_prevYear), "no info",
       ( ([Measures].[Streams 1month] - Streams_prevYear) / Streams_prevYear )
    ), format_string = "Percent"

SELECT
  { [Measures].[Streams 1month], Streams_prevYear, percChange } ON COLUMNS,
  NonEmpty(
    ( [DimDate].[Year].[Year], [DimCategory].[Category].[Category] )
  ) ON ROWS
FROM [Group_ID_13_DSV]
```

Listing 3: Yearly Category Trends

Nel blocco `SELECT`, le misure `Streams 1month`, `Streams_prevYear` e `percChange` vengono visualizzate sulle colonne, mentre sulle righe viene utilizzata una combinazione di `Year` e `Category`. L'uso di `NONEMPTY` consente di limitare l'output alle sole categorie che presentano valori di stream, migliorando la leggibilità dei risultati.

Year	Category	Streams 1month	Streams_prevYear	percChange
0	DANCE	220 796	(null)	no info
0	POP	85 744	(null)	no info
1992	DANCE	4 912	(null)	no info
1993	DANCE	46 267	4 912	841.92%
1993	MINIMAL	93 372	10 707	772.07%
1994	POP	11 528	16 785	-31.32%
1995	MINIMAL	9 788	56 671	-82.73%
1996	MINIMAL	193 956	9 788	1881.57%

Tabella 3: Esempio di output della query MDX: variazione percentuale degli stream per categoria rispetto all'anno precedente

6.4. Categorie con performance stagionali superiori alla media (Assignment18)

Questa query è stata progettata per individuare, per ciascuna stagione, le categorie musicali che nel periodo corrente registrano un numero di stream superiore alla media della stessa stagione nell'anno precedente e per quantificare tale incremento in termini percentuali. A tal fine viene definita la misura calcolata `PrevYearSeasonAvg`, che utilizza la funzione `AVG` per calcolare la media degli stream dell'anno precedente nella stessa stagione, considerando esclusivamente le categorie che presentano valori effettivi tramite l'uso di `NONEMPTY`, così da evitare che categorie assenti influenzino il valore di riferimento. Successivamente viene definita la misura `PercIncrease`, che esprime la variazione percentuale tra gli stream correnti e la media stagionale dell'anno precedente.

```
WITH
  MEMBER PrevYearSeasonAvg AS
    Avg(
      NonEmpty(
        [DimCategory].[Category].[Category],
        ( [DimDate].[Year].PrevMember, [DimDate].[Season].CurrentMember, [Measures].[Streams 1month] )
      ),
      ( [DimDate].[Year].PrevMember, [DimDate].[Season].CurrentMember, [Measures].[Streams 1month] )
    )

  MEMBER PercIncrease AS
    ( [Measures].[Streams 1month] - PrevYearSeasonAvg ) / PrevYearSeasonAvg,
    FORMAT_STRING = "Percent"

SELECT
  { [Measures].[Streams 1month], PrevYearSeasonAvg, PercIncrease } ON COLUMNS,
  NonEmpty(
    Filter(
      ( [DimDate].[Year].[Year], [DimDate].[Season].[Season], [DimCategory].[Category].[Category] ),
      [Measures].[Streams 1month] > PrevYearSeasonAvg AND PrevYearSeasonAvg > 0
    )
  ) ON ROWS
FROM [Group_ID_13_DSV]
```

Listing 4: Seasonal Over-Performers

Nel blocco `SELECT` le misure `Streams 1month`, `PrevYearSeasonAvg` e `PercIncrease` sono riportate sulle colonne, mentre ulle righe viene utilizzata la combinazione di `Year`, `Season` e `Category`, filtrata tramite una condizione `FILTER` in cui sono mantenuti esclusivamente i casi in cui il valore corrente di `Streams 1month` è maggiore della media della stessa stagione nell'anno precedente (`PrevYearSeasonAvg`) e per cui tale media risulta positiva.

Year	Season	Category	Streams 1month	PrevYearSeasonAvg	PercIncrease
1993	summer	MINIMAL	81 710	10 707	663.15%
1993	winter	DANCE	46 267	4 912	841.92%
1994	winter	MINIMAL	52 137	19 876.5	162.30%
1996	summer	SOFT POP	28 896	9 788	195.22%
1998	spring	POP	29 428	8 757	236.05%
1999	winter	MINIMAL	163 814	17 913.75	814.46%
2000	spring	DANCE	69 738	14 981.5	365.49%

Tabella 4: Esempio di output della query MDX: categorie con stream superiori alla media stagionale dell'anno precedente

6.5. Analisi avanzata di business (Assignment 19)

Come ultimo assignment sulle query MDX, l'analisi si è focalizzata sull'individuazione di una metrica in grado di cogliere l'evoluzione del peso relativo delle categorie musicali nel tempo, andando oltre la semplice osservazione dei volumi di stream. Si è quindi scelto di analizzare l'evoluzione della quota di ciascuna categoria anno su anno, così da individuare i generi che stanno effettivamente guadagnando rilevanza nel mercato complessivo, anche in presenza di volumi assoluti non dominanti.

```
WITH
  MEMBER YearTotal AS ( [DimCategory].[Category].[All], [Measures].[Weighted Streams] )
  MEMBER Share AS [Measures].[Weighted Streams] / YearTotal, FORMAT_STRING = "Percent"
  MEMBER PrevYearShare AS ( [DimDate].[Year].PrevMember, Share ), FORMAT_STRING = "Percent"
  MEMBER ShareDelta AS Share - PrevYearShare, FORMAT_STRING = "Percent"

  SET Cand AS
    Filter(
      NonEmpty(
        Filter( [DimDate].[Year].[Year], [DimDate].[Year].CurrentMember.Name <> "0" )
        * [DimCategory].[Category].[Category],
        [Measures].[ShareDelta]
      ),
      [Measures].[ShareDelta] > 0
    )

SELECT
  { [Measures].[Weighted Streams], Share, PrevYearShare, ShareDelta } ON COLUMNS,
  TopCount( Cand, 10, ShareDelta ) ON ROWS
FROM [Group_ID_13_DSV]
```

Listing 5: Advanced MDX Insight: Top Growing Categories

Dal punto di vista tecnico, la query definisce alcune misure calcolate tramite `WITH MEMBER`. La misura `yeartotal` rappresenta il totale annuale degli stream ponderati, calcolato aggregando

`Weighted Streams` su tutte le categorie, mentre la misura `share` esprime la quota percentuale di ciascuna categoria rispetto a tale totale. Successivamente, `prevyearshare` recupera la quota della stessa categoria nell'anno precedente e `sharedelta` ne calcola la variazione anno su anno. Nei casi in cui il valore dell'anno precedente non sia disponibile o non sia significativo (ad esempio quando l'anno precedente coincide con il membro speciale `Year = 0` o non esistono dati per quella categoria), la quota precedente risulta `Null`, indicando l'impossibilità di effettuare un confronto valido. Per rendere l'analisi significativa, vengono esclusi l'anno speciale `Year = 0` e le categorie che non presentano una crescita di quota. Infine, tramite `TOPCOUNT`, la query seleziona le dieci categorie con il maggiore incremento di share, evidenziando i generi musicali che mostrano la crescita più rilevante in termini di peso relativo.

Year	Category	Weighted Streams	Share	PrevYearShare	ShareDelta
1995	MINIMAL	7 830.4	100.00%	44.75%	55.25%
2004	RAP	820 326.0	54.23%	8.03%	46.20%
1996	DANCE	119 552.8	35.20%	(Null)	35.20%
2002	SOFT POP	118 919.2	39.76%	6.78%	32.98%
1997	MINIMAL	65 272.8	77.11%	46.01%	31.10%
2016	DANCE	7 092 290.0	39.26%	15.51%	23.74%

Tabella 5: Esempio di output (Assignment 19): top casi con aumento positivo della quota rispetto all'anno precedente.

7. Dashboards & Visual Analytics

7.1. Analisi geografica per categoria (Assignment 20)

Per l'Assignment 20 è stato realizzato un *plot* in Power BI con l'obiettivo di analizzare il totale degli stream mensili in funzione della città di nascita degli artisti, distinguendo il contributo delle diverse categorie musicali. È stato utilizzato un grafico a colonne impilate, che consente di confrontare sia il volume complessivo degli stream per ciascuna città sia la loro composizione per categoria. Sull'asse delle X è riportata la variabile `City`, rappresentativa della città di nascita dell'artista, mentre sull'asse delle Y è stata utilizzata la misura `Streams 1month`, che indica il numero totale di stream dopo un mese. La legenda del grafico è basata sulla variabile `Category`, permettendo di visualizzare il contributo delle diverse categorie musicali (ad esempio `DANCE`, `POP`, `RAP`, ecc.) al totale degli stream di ciascuna città. Per rendere l'analisi più leggibile e significativa è stato applicato un filtro che esclude i casi in cui la città di nascita è impostata a `Unknown`, evitando

che valori geografici non definiti influenzino l'interpretazione dei risultati. Il *plot* consente così di individuare rapidamente le città di origine degli artisti con il maggiore impatto in termini di stream e di osservare come il successo sia distribuito tra le diverse categorie musicali.

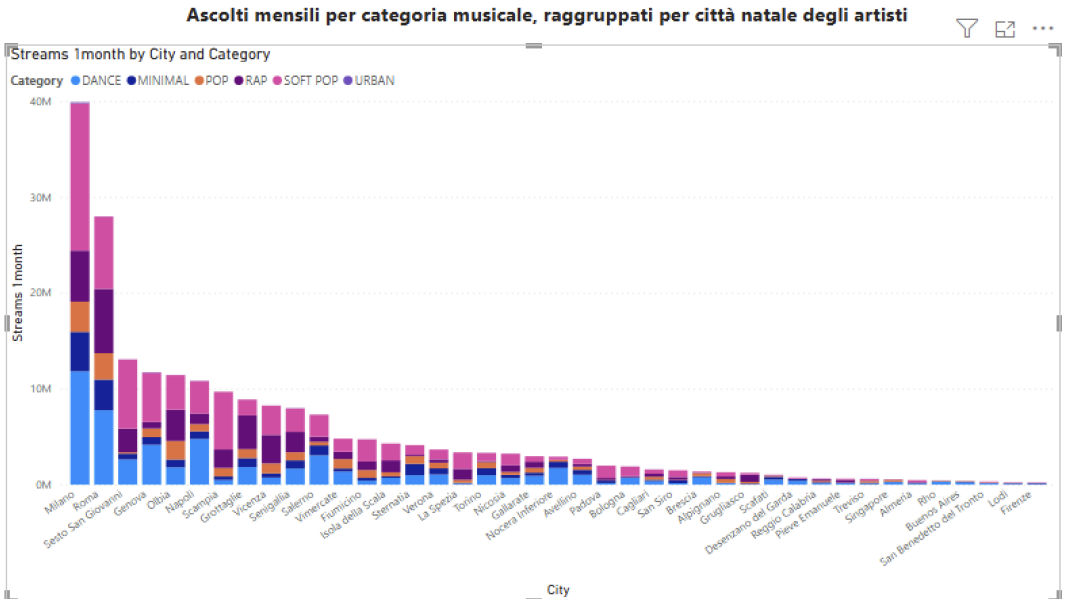

Figura 6: Plot per l'Assignment 20

7.2. Analisi dei testi delle canzoni (Assignment 21)

Per l'Assignment 21 l'attenzione è stata posta sui dati relativi ai testi delle canzoni disponibili nel cubo, con l'obiettivo di esplorarne il possibile legame con le performance in termini di ascolti. Per questo motivo abbiamo scelto di realizzare due visualizzazioni complementari, ciascuna focalizzata su un aspetto diverso dell'informazione testuale: la lunghezza dei testi e l'uso di parole esplicite italiane.Il primo grafico (v. Fig. 7) analizza la relazione tra la lunghezza del testo dei brani e il loro successo. Sull'asse X sono riportati i brani (identificati da `Track` e `Artist`), mentre sull'asse Y è rappresentata la misura `Streams 1month`. La legenda utilizza la variabile `n Tokens`, suddivisa in classi, che indica il numero di parole presenti nel testo di ciascun brano. La visualizzazione è limitata ai 15 brani più ascoltati tramite un filtro *Top N*. I risultati mostrano che i brani con il maggior numero di stream non sono necessariamente quelli con testi più lunghi, suggerendo che la quantità di parole non è un fattore determinante del successo. Il secondo grafico (v. Fig. 8) si concentra invece sull'uso di parole esplicite italiane nei testi e sulla loro distribuzione geografica. Sull'asse X è riportata la variabile `Swear IT`, organizzata in classi che rappresentano la frequenza di termini espliciti, mentre sull'asse Y è nuovamente utilizzata la misura `Streams 1month`. La legenda rappresenta la dimensione `Region`, permettendo di confrontare le diverse aree italiane. Sono stati esclusi i valori `Unknown` per evitare distorsioni dovute a informazioni mancanti. Il gra-

fico evidenzia che la maggior parte degli stream si concentra nelle fasce con un uso basso o medio di parole esplicite, con differenze rilevanti tra le regioni.

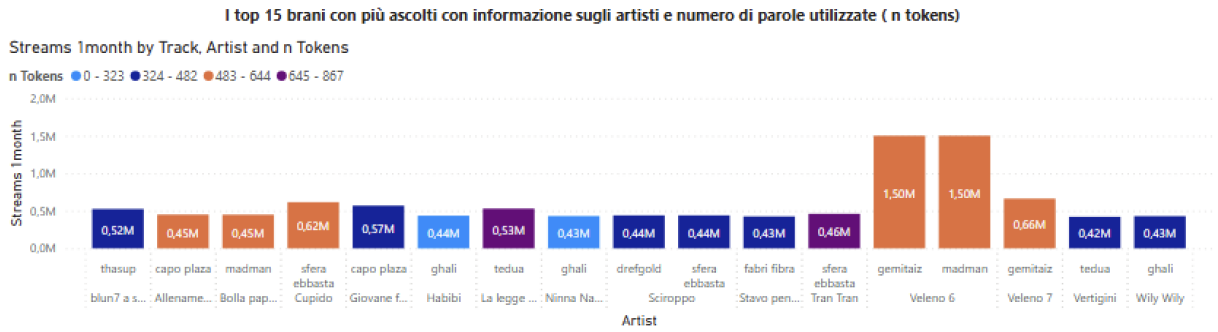

Figura 7: Primo plot per l'Assignment 21

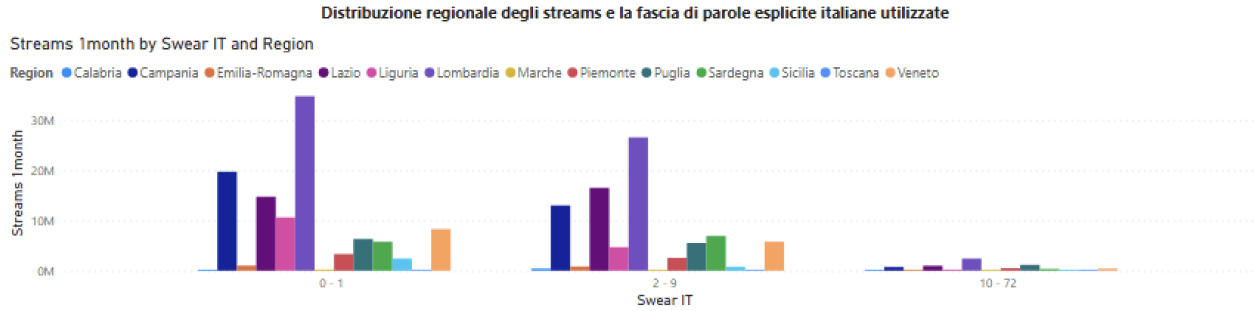

Figura 8: Secondo plot per l'Assignment 21

7.3. Trend temporali delle categorie musicali (Assignment 22)

Per l'Assignment 22 l'analisi si è concentrata sull'evoluzione temporale delle categorie musicali, al fine di osservare come il peso dei diversi generi cambi nel tempo. È stata quindi realizzata una visualizzazione che permette di confrontare, anno per anno, l'andamento degli stream complessivi e il contributo delle singole categorie musicali. Il grafico (v. Fig. 9) mostra sull'asse X la dimensione temporale `Year` (limitata agli anni reali, `Year > 0`) e sull'asse Y la misura `Streams 1month`. La legenda si basa sulla dimensione `Category` e la visualizzazione, realizzata come line chart, consente di evidenziare sia le tendenze individuali sia le differenze di intensità tra i generi.

Fino ai primi anni 2000 i volumi di stream risultano contenuti per tutte le categorie, con un andamento sostanzialmente stabile. A partire dalla metà degli anni 2000 si osserva una crescita progressiva, che diventa più marcata dal periodo 2013–2014 in poi. Le categorie `POP`, `RAP` e `MINIMAL` mostrano un andamento relativamente regolare nel tempo, con variazioni contenute e una crescita graduale. Al contrario, `SOFT POP` e `DANCE` evidenziano andamenti più volatili, caratterizzati da picchi pronunciati in specifici intervalli temporali ad esempio nel 2018 e 2020, contribuendo

in modo significativo alle fasi di maggiore espansione del mercato. La categoria `URBAN`, invece, mantiene valori complessivamente più bassi lungo l'intero periodo osservato, con un contributo limitato rispetto alle altre. Nel complesso, il grafico mette in evidenza come l'evoluzione degli stream nel tempo sia guidata sia da categorie con crescita stabile sia da generi caratterizzati da forti picchi, delineando un mercato musicale eterogeneo e dinamico.

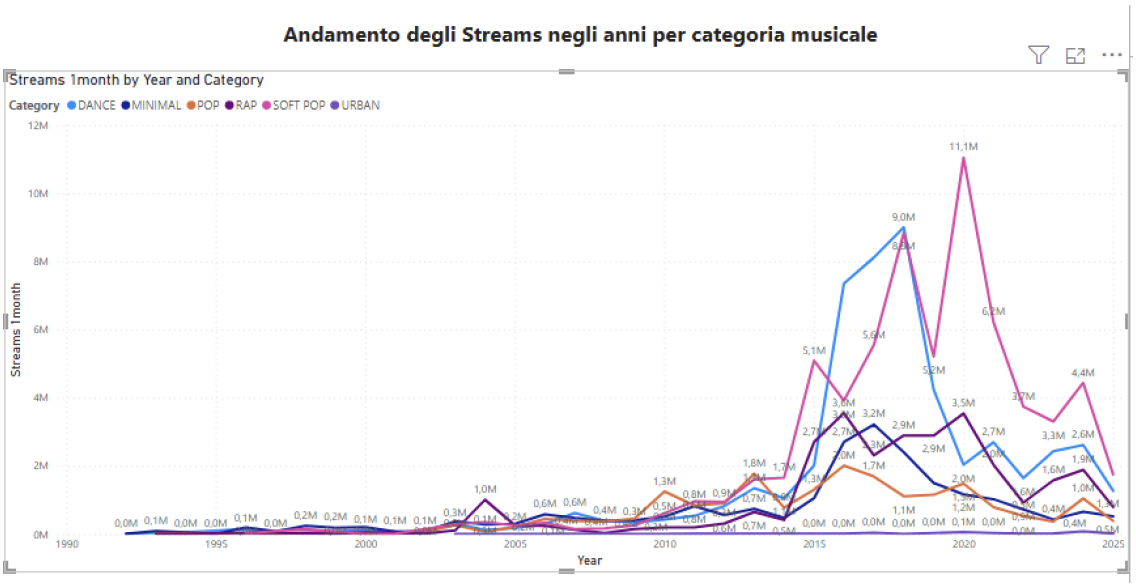

Figura 9: Plot per l'Assignment 22

8. Conclusion

Il progetto ha mostrato come dati diversi e inizialmente disordinati possano essere organizzati in un sistema utile per supportare le decisioni. Il punto di forza principale è la costruzione di una pipeline completa, dalla pulizia dei dati fino alle analisi finali. Le difficoltà maggiori hanno riguardato la scarsa qualità dei dati di partenza e le informazioni mancanti sugli artisti, risolte con interventi di pulizia ed arricchimento. L'uso di SSIS e del cubo OLAP ha reso le analisi più veloci e coerenti. Nel complesso, il sistema permette di analizzare trend, stagionalità e performance degli artisti, offrendo risultati chiari e utili per le scelte strategiche della record label.